

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Московский Авиационный Институт»
(Национальный Исследовательский Университет)

Институт: №8 «Информационные технологии
и прикладная математика»
Кафедра: 806 «Вычислительная математика
и программирование»

Отчет по лабораторной работе №1
по предмету «Информационный поиск»

«Добыча корпуса документов»

Группа: М8О-412Б-22

Студент(ка): Кайдалова А. А.

Оценка:

Дата сдачи:

Москва, 2025

Задание

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

Журнал выполнения задания

Тема. Я выбрала тему для корпуса документов, который буду использовать во всех лабораторных работах. Тема – **материнство**. Мой выбор пал на данную сферу, так как в интернете есть большое количество статей, форумов и других источников для парсинга, также это важная социальная область.

Источники данных, которые я нашла: letidor.ru 7ya.ru, mama.ru.

Поисковики. Чтобы удостовериться, что выбранные источники подходят для лабораторных, в поисковой строке Google я ввела такой запрос: «первый прикорм схема site: letidor.ru OR site:7ya.ru OR site:mama.ru». При этом использовался оператор site: и логический оператор OR для объединения результатов с нескольких сайтов. Google выдал страницы, соответствующие запросу, но только с сайтов, которые я указала. Значит, мой корпус документов уже проиндексирован и доступен для поиска через мощную существующую систему. Посмотрим еще один запрос: «режим дня ребенка 2 лет» site:mama.ru Google возвращает релевантные статьи, но в выдаче присутствуют форумные темы и страницы категорий, что снижает точность. Можно

сказать, что существующие системы (Google, внутренние поиски сайтов) позволяют находить документы, но выдача содержит шум, отсутствует ранжирование по качеству контента.

Характеристики документов из разных источников.

Источник **7ya.ru**: семейный сайт. В html конкретной публикации есть сама статья, ее содержание, статья дня, похожие статьи, читайте также, поделитесь, похожие темы и тд. Мета-информация и разметка текста: в `<head id="Head1"> <title>` тема статьи, в блоке `<main id="article" role="main" class="article"> <div itemprop="articleBody" class="articlebody">` `<p>` идет текст, внутри которого встречаются картинки `<div class="c-pic">` и дата публикации и изменений `<meta itemprop="datePublished" content=""/>` `<meta itemprop="dateModified" content="` и в `<div class="articlepubdate"> <div class="pubdate">`31.03.2025`</div> <div class="update">`Обновлено 31.03.2025`</div> </div>`. Также могут встречаться статьи только с датой публикации, с ссылками в тексте `<a title="` `class="wordlink" href="` ``, без картинок. Два примера размера сырого документа на этом сайте – 351 КБ, 348 КБ. В извлеченном тексте из первого примера всего символов (включая пробелы, знаки препинания): 5368, всего букв (без учета знаков препинания и пробелов): 8262. В извлеченном тексте из второго примера всего символов (включая пробелы, знаки препинания): 5013, всего букв (без учета знаков препинания и пробелов): 8006. **Итог:**

- Статья находится в `<div class="articlebody">`;
- Метаданные: `<title>`, `<meta itemprop="datePublished">`, автор в ссылке;

Источник **mama.ru**: сайт со статьями на разные темы материнства и беременности. На нем вкладки с разными темами статей, можно перейти на любую из них и выбрать конкретную публикацию для анализа. Рассмотрим html: `<title>` с темой, есть указания на другие статьи, вход, регистрация и тд. В блоке `<h4 class="fw-bold text-secondary mb-0">` ссылки на темы статьи. В `<h1 class="fw-bold" itemprop="headline">` также указана тема, `<div class="article-lead--text fw-semibold text-primary">` время прочтения, `<div class="article-lead--text mt-2"><p dir="ltr">` тут уже идет текст статьи, в нем встречаются заголовки `<h2 dir="ltr" id="period-novorozhdenosti-0-1-mesyac">`, перечисления `<li dir="ltr" aria-level="1">`, картинки `<figure class="image"><img src=`, автор `<h5 class="fw-semibold small-text-on-mobile">`, `<h5 class="fw-semibold small-text-on-mobile">` дата публикации, ссылки на литературу `<div class="collapse" id="articleCollapseList"><p dir="ltr">`. В статьях может не быть указание автора, картинок. Два примера размера сырого документа на этом сайте – 587 КБ, 587 КБ. В извлеченном тексте из первого примера всего символов (включая пробелы, знаки препинания): 6491, всего букв (без учета знаков препинания и пробелов): 5352. В извлеченном тексте из второго примера всего символов (включая пробелы, знаки препинания): 7425, всего букв (без учета знаков препинания и пробелов): 6038. **Итог:**


- Текст — в блоках `<div class="article-lead--text mt-2">`;
- Метаданные: `<h1 itemprop="headline">`, автор в `<h5>`, дата публикации;

Источник **letidor.ru**: сайт со статьями на темы для родителей: психология, образование, здоровье, право, звезды и дети и другие. На нем есть навигационное меню с рубриками, можно перейти на любую из них и выбрать конкретную публикацию для чтения. Рассмотрим html: `<title>` содержит название статьи и название сайта, есть мета-теги с описанием (description), указания на социальные сети, рекламные скрипты и т.д. В шапке сайта присутствует логотип, меню основных разделов, кнопки входа и регистрации. Данные о статье, включая текст, подгружаются динамически и отображаются в блоке с классами ``jsx-...``. Заголовок статьи представлен в элементе `<h1>`. Анонс или введение статьи можно найти в мета-теге ``og:description`` или в атрибутах JSON-данных, встроенных в страницу (в теге `<script>` с ``__REACT_QUERY_STATE__``). Текст статьи разбит на виджеты (widgets) типа ``markdown``, ``image``, ``incut``, ``readMore``. Непосредственный текст статьи находится в ``widgets`` с ``"type":"markdown"`` внутри атрибута ``"body"``. В тексте встречаются подзаголовки, оформленные как ``### Заголовок``, перечисления, могут быть картинки (``"type":"image"`` с атрибутами ``versions`` и ``credits``), блоки "Читайте также" (``"type":"readMore"``), врезки (``"type":"incut"``). Информация об авторе, дате публикации, времени чтения содержится в JSON-данных (в ``attributes`` статьи: ``published_at``, ``read_duration``, а также в связанных данных автора ``person``). В статьях может не быть указания конкретного автора (например, если материал редакционный). В конце статьи могут быть ссылки на использованные источники или фото. Примерный размер сырого HTML-документа на этом сайте – 498 КБ, 587 КБ. В извлеченном чистом тексте из примера всего символов (включая пробелы, знаки препинания): 8510, всего букв (без учета знаков препинания и пробелов): примерно 3043. В извлеченном тексте из второго примера всего символов (включая пробелы, знаки препинания): примерно 3896, всего букв (без учета знаков препинания и пробелов): примерно 5708. **Итог:**

- Основной текст содержится в JSON-объектах внутри `<script>` под ключом "widgets" с `"type":"markdown"`;
- Дата, автор, время чтения — в структурированных данных (`published_at`, `person`);

Результаты

После выполнения 2 лабораторной был собран корпус из 54 543 документов.

	 A-Z source	123 article_count
1	7ya.ru	8 417
2	letidor.ru	40 685
3	mama.ru	5 441

Дальнейшие значения получены путем запросов к бд (брала случайные 1000 документов для ускорения работы запросов).

Количество документов	54 543
Источники	7ya.ru, mama.ru, letidor.ru
Средний размер сырого HTML	304.625 КБ
Средний размер извлеченного текста	3 192 символов, 5.66 КБ
Общий объем бд	8 ГБ

Выводы

Корпус документов по теме материнство:

- Уникален;
- Достаточно велик (54 543 документов);
- Проиндексирован существующими поисковиками;
- Содержит структурированные метаданные (автор, дата, заголовок).

Приложения

Код из 2 лабораторной для извлечения текста:

```
def extract_article_text(html, source_url):  
    soup = BeautifulSoup(html, 'html.parser')  
    for tag in soup(["script", "style", "nav", "footer", "aside", "header"]):  
        tag.decompose()  
  
    try:  
        for script in soup.find_all("script", type="application/ld+json"):  
            data = json.loads(script.string)  
            if isinstance(data, dict) and "articleBody" in data:  
                return data["articleBody"].strip()  
    except (ValueError, KeyError, TypeError):  
        pass  
  
    content = None  
  
    if "7ya.ru" in source_url:  
        content = soup.select_one('.articlebody')  
    elif "mama.ru" in source_url:
```

```

lead = soup.select_one('.article-lead--text.mt-2')
lead_text = ""
if lead:
    p_tag = lead.find('p')
    if p_tag:
        lead_text = p_tag.get_text(strip=True)
article_block = soup.select_one('.article-block')
main_text = ""
if article_block:
    for tag in article_block(["script", "style", "nav", "footer", "aside", "header"]):
        tag.decompose()
    main_text = ' '.join(article_block.get_text().split())
    full_text = ' '.join([lead_text, main_text]).strip()
    return full_text if full_text else ""
elif "letidor.ru" in source_url:
    texts = soup.select('div[data-qa="text"]')
    if texts:
        full_text = ' '.join(t.get_text().strip() for t in texts)
        return full_text
else:
    content = soup

return ' '.join(content.get_text().split()) if content else ''

```

Код из 2 лабораторной для извлечения метаданных:

```

def extract_article_metadata(html, source_url):
    soup = BeautifulSoup(html, 'html.parser')
    title = ""
    author = ""
    publish_date = ""

    try:
        for script in soup.find_all("script", type="application/ld+json"):
            data = json.loads(script.string)
            if isinstance(data, dict):
                title = data.get("headline", "").strip()
                author_obj = data.get("author", {})
                if isinstance(author_obj, dict):
                    author = author_obj.get("name", "").strip()
                elif isinstance(author_obj, str):
                    author = author_obj.strip()
                dt = data.get("datePublished", "")
                if dt:
                    publish_date = dt.split("T")[0]
                if title and author and publish_date:
                    return title, author, publish_date
    except (ValueError, KeyError, TypeError):
        pass

    if "7ya.ru" in source_url:
        title_tag = soup.select_one('h1[itemprop="headline"]')
        author_tag = soup.select_one('div.type a[href*="club.7ya.ru"]')
        date_tag = soup.find('meta', {'itemprop': 'datePublished'})
        title = title_tag.get_text(strip=True) if title_tag else ""
        author = author_tag.get_text(strip=True) if author_tag else ""
        publish_date = date_tag['content'] if date_tag and date_tag.get('content') else ""

    elif "mama.ru" in source_url:
        title_tag = soup.select_one('h1[itemprop="headline"]')
        author_tag = soup.select_one('h5.fw-semibold.small-text-on-mobile')
        date_meta = soup.find('meta', {'itemprop': 'datePublished'})
        publish_date = ""
        if date_meta and date_meta.get('content'):
            publish_date = date_meta['content'].split('T')[0]
        title = title_tag.get_text(strip=True) if title_tag else ""

```

```
author = author_tag.get_text(strip=True) if author_tag else ""
elif "letidor.ru" in source_url:
    title_tag = soup.select_one('h1[data-qa="lb-topic-header-texts-title]')
    title = title_tag.get_text(strip=True) if title_tag else ""
    author_tag = soup.select_one('div.jsx-1196406913 a.link')
    author = author_tag.get_text(strip=True) if author_tag else ""
    date_div = soup.select_one('div.J57431KZ.M7gu8GJc')
    if date_div:
        date_text = date_div.get_text().strip()
        match = re.search(r'(\d{1,2})\s+([а-яА-Я])\s+(\d{4})', date_text)
        if match:
            day, month_ru, year = match.groups()
            months = {
                "января": "01", "февраля": "02", "марта": "03", "апреля": "04",
                "мая": "05", "июня": "06", "июля": "07", "августа": "08",
                "сентября": "09", "октября": "10", "ноября": "11", "декабря": "12"
            }
            month = months.get(month_ru, "01")
            publish_date = f"{year}-{month}-{day.zfill(2)}"
    return title, author, publish_date
```